时间复杂度优化策略说明（Feature Engineering & Verify）

1. 优化目标

在不改变业务语义和特征定义的前提下，降低“验证与处理阶段”的运行时间和 I/O 次数，核心目标包括：

- 减少对原始数据表的重复全量遍历；
- 将同层级、同窗口、同类型特征统一批量计算；
- 将逐列循环计算改为矩阵化/批量化统计；
- 先粗筛再精筛，缩小高成本计算（相关性/AUC/IV）的输入规模。

2. 原流程复杂度分析（优化前）

- N：样本行数
- F：候选特征数
- W：时间窗口个数（如 1d/3d/7d）
- B：行为类别数（view/fav/cart/buy）
- G：分组层级数（item/user/user-item）
- P：高相关特征对数量（$P \leq \frac{F(F-1)}{2}$）
- N_s：相关矩阵计算时使用的样本数（若抽样则 $N_s < N$）

2.1 特征工程阶段

若按“层级 × 窗口 × 行为”分别写聚合，典型复杂度近似：

$$T_{before}^{feat} \approx O(G \cdot W \cdot B \cdot N)$$

且每次聚合会触发一次扫描，I/O 与 CPU 缓存命中均较差。

2.2 验证阶段

- 缺失率/方差逐列扫描：$O(F \cdot N)$
- 高相关冗余：相关矩阵通常 $O(F^2 \cdot N)$
- AUC/IV 若对全部特征执行：
- AUC（排序）近似 $O(F \cdot N\log\ N)$
- IV（分箱）近似 $O(F \cdot N)$

总体容易成为：

$$T_{before}^{verify} \approx O(F^2N + FN\log\ N)$$

3. 优化策略与实现

3.1 特征工程：统一聚合，减少重复遍历

策略：

1. 先按最大窗口一次过滤数据；
2. 通过区间连接为每条行为标注所属窗口；
3. 对每个层级仅执行一次 group by(keys, win, behavior)；
4. 用 dcast 一次性展开所有窗口×行为列；
5. 比率特征在宽表上批量生成。

效果：

- 将“多次扫描 + 多段聚合”压缩为“少次扫描 + 单次核心聚合”；
- 复杂度由 $O(GWBN)$下降到近似：

$$T_{after}^{feat} \approx O(N) + O(G \cdot N) + O(G \cdot K)$$

其中 K为生成列数（通常远小于重复扫描成本）。

3.2 验证阶段：分层筛选 + 批量统计

策略：

1. 矩阵化粗筛：缺失率、方差一次矩阵运算；
2. 相关性后置：只在粗筛后特征集合上计算相关矩阵；
3. AUC/IV 限域计算：仅对二次筛后的候选特征执行；
4. 统一函数化应用：train/val/test 复用同一套筛选列，避免重复逻辑与错误。

效果：

- 将高成本步骤输入规模从 F缩小到 F_1, F_2, F_3（逐级递减）；
- 复杂度从：

$$O(F^2N + FN\log N)$$

优化为：

$$O(FN) + O(F_1^2 N_s) + O(F_2 N\log N) + O(F_3 N)$$

其中 $F_1, F_2, F_3 \ll F$，N_s 是相关性计算时的抽样行数。

4. 实现说明

1. 使用统一的 win_day 映射代替多段窗口子集扫描。
2. 将 user/item/ui 三层的窗口行为统计统一为“分组后透视”流水线。
3. 相关性筛选中，预先计算并缓存 lab_cor 与 var_map，在 pair 决策中只查表。
4. 引入矩阵化方差计算（matrixStats::colVars）替换逐列遍历统计。
5. AUC/IV 移到相关剔除后执行，减少计算特征数。
6. 训练/验证/测试应用同一 keep_cols，避免重复逻辑和额外开销。

5. 结果与收益总结

- 遍历次数显著减少：同组特征不再重复扫描全表；
- 验证阶段运行时间缩短：高成本算法仅在小候选集上执行；
- 代码可维护性提升：统一函数与批量逻辑减少重复代码与不一致风险；
- 可扩展性增强：新增窗口/行为类型只需改配置，不需复制大段聚合代码。

6. 正确性与一致性说明

优化只改变“计算组织方式”，不改变以下内容：

- 窗口定义（1d~7d）；
- 行为类别语义（view/fav/cart/buy）；
- 各层级特征定义（user/item/ui）；
- 筛选规则阈值（如 corr threshold、IV/AUC 阈值）。

因此模型输入语义保持一致，结果差异仅可能来自数值稳定性或 tie-break 细节，不影响方法论一致性。

7. 风险与边界条件

1. 相关矩阵内存压力：当 F很大时，cor(X) 占用 $O(F^2)$内存。

- 先粗筛、再计算；或用分块相关。

2. AUC 排序开销：N 极大时排序成本高。

- 分桶近似 AUC 或抽样估计做预筛。

3. IV 分箱稳定性：极端稀疏特征可能分箱退化。

- 现已通过平滑项 eps 与退化分支保护。