模型评估报告：GLM（线性）

1. 项目与任务定义

• 任务目标：基于用户行为统计特征（user / item / user-item 多层特征），预测该 (user_id, item_id) 是否会产生购买行为（label_buy）。
• 任务类型：二分类（购买=1 / 不购买=0）。
• 模型：加权 Logistic Regression（GLM, binomial）：使用样本权重处理类别不平衡（正类权重提升）。

2. 模型训练与评估策略

2.1 阈值与两类指标体系

包含两类指标：
(1) 阈值无关（排序能力）指标
• AUC-ROC：衡量模型对"正样本排在负样本前"的能力（越大越好）。
• PR-AUC：在正类稀少时更敏感的排序指标（越大越好）。
注意：AUC/PR-AUC 是基于概率排序的，不依赖分类阈值，所以在阈值扫描表里它们通常不变或变化很小，这是正常的。
(2) 阈值相关（落地分类）指标
• Precision / Recall / F1 / Accuracy：依赖你选定的阈值（threshold）。
• LogLoss：概率校准误差（越小越好），反映"预测概率是否可信"。

2.2 阈值选择策略

• 验证集阈值扫描，并选择 F1 最大的阈值作为最终阈值。
• 最终选择阈值为：0.05

3. 评估结果（真实输出）

3.1 验证集最优结果（VAL，threshold=0.05）

• Threshold：0.05
• AUC-ROC：0.6629
• PR-AUC：0.0378
• Accuracy：0.7243
• Precision：0.0425
• Recall：0.5217
• F1：0.0787
• LogLoss：7.3895

解读：

1. 排序能力：AUC≈0.663：明显优于随机（0.5），但强度一般（通常 0.75+ 才算明显强模型）。
2. PR-AUC≈0.03：在购买为少数类场景下，PR-AUC 常较低；该值说明模型对正类的排序提升有限。
3. 分类层面：Recall≈0.52、Precision≈0.043 → F1≈0.079：模型在这个阈值下属于"偏召回"的策略：能找回约一半正类，但误报多（预测为买的样本里只有约 4.25% 真的买）。
4. LogLoss 很高（7.39）：概率校准较差/输出概率分布异常/共线性导致系数不稳定，需要后续修正。

3.2 测试集结果（TEST，仍用 threshold=0.05）

- Threshold：0.05
- AUC-ROC：0.6700
- PR-AUC：0.0405
- Accuracy：0.7387
- Precision：0.0444
- Recall：0.5226
- F1：0.0818
- LogLoss：6.7939

解读：泛化稳定且略好

TEST 的 AUC/PR-AUC/F1 都略高于 VAL（AUC 0.670 > 0.663，F1 0.0818 > 0.0787），说明：

1. 没出现"验证集好、测试集崩"的过拟合现象；
2. 切分策略与训练流程整体稳定；
3. 但整体仍属于 baseline 水平（可用来对比更强模型）。

3.3 阈值扫描结果的结论

1. 最优阈值非常低（0.05）
   - 典型不平衡分类：如果用默认 0.5，模型会预测为"买"的太少，Recall 会更差。
   - 0.05 说明：模型输出的购买概率整体偏低或正类确实稀少，需要阈值调节才能落地。
2. Precision/Recall/F1 随阈值变化不大
   - 预测概率的分布"挤在某个区间"，调阈值不会产生很大结构性变化。
   - 很难通过阈值显著提升 Precision（精确率）；
   - 更需要通过 更强模型/更好特征/更合理标签来提升区分度。

4. 特征重要性分析

4.1 强特征（显著且影响大）

按|z|值排序，你最强的一批特征集中在 user-item 交互强度 与 商品整体转化特征：

- ui_act_total（z=9.44，p≈3.86e-21）
  user-item 总交互次数越多，购买概率越高（强正相关）
- ui_cart_rate（z=7.58，p≈3.46e-14）
  user-item 加购/浏览比越高，购买概率越高（强正相关）
- i_buy_share（z=7.25，p≈4.12e-13）
  商品购买占比越高，越可能买（商品"更容易转化"）
- i_buy（z=5.93，p≈3.08e-09）
  商品历史购买越多（热度/受欢迎），更可能买
- i_user_nunique（z=4.54，p≈5.61e-06）
  互动过该商品的用户越多，商品越热门，购买概率更高

模型主要依赖 "用户-商品交互强度/转化倾向（ui）" + "商品热度/转化（i）" 来区分是否购买。

4.2 弱特征（不显著或贡献很小，可作为删减候选）

共有 20 个特征 p>0.05，说明在 GLM 线性框架下它们对结果的贡献不稳定或被共线性稀释。

最弱的几个（p 接近 1）：

- ui_user_item_buy_rate_mix（p≈0.995，几乎没用）
- i_view_6d（p≈0.969）

- u_buy（p≈0.934）
- u_fav（p≈0.872）
- u_fav_rate（p≈0.426）

注意：GLM 的“不显著”不等于“完全没用”，因为你的计数/窗口特征很容易高度相关（共线性），会造成“贡献被分摊”。更稳的删特征依据应该综合：单变量 AUC/IV + 多变量置换重要性 + 共线性过滤。

4.3 异常信号：系数极端大（±100 级别）

出现了非常极端的系数（例如 u_cart ≈ -143、i_act_total ≈ -105、ui_user_item_pop ≈ +119）。通常意味着至少存在一种问题：

1. 严重共线性：大量计数/窗口特征重复表达同一信息
2. 尺度/分布问题：部分特征量级很大或分布极端，导致 GLM 系数不稳定
3. 近似分离：某些特征在某些范围几乎决定标签，使得系数飙升

也能解释为什么 LogLoss 非常高：概率输出校准不可靠。

5. 高偏差/高方差，过拟合/欠拟合分析

从偏差—方差分析结果来看，GLM 模型表现出明显的高方差特征。训练集 AUC 为 0.9987，训练 logloss 为 0.0336，说明模型在训练集上拟合得非常充分；但验证集 AUC 仅为 0.5348，验证 logloss 高达 23.2786，说明模型在未见数据上的泛化能力极差，存在严重过拟合。按照过欠拟合的语言来描述，这一结果应判定为明显过拟合，而不是欠拟合。

进一步看学习曲线，GLM 在 frac=0.1 到 frac=0.6 的多个训练子样本上训练 AUC 都接近 1，训练 logloss 也接近 0，但验证 AUC 仅在 0.49 到 0.62 之间波动，验证 logloss 也非常不稳定，说明模型对训练样本变化十分敏感。随着样本量增加，训练集与验证集之间的性能差距并没有稳定缩小，因此问题并不只是样本量不足，更可能说明当前线性假设并不适合该任务，或者特征共线性及加权逻辑回归的概率输出问题共同导致了泛化失效。

6. 学习曲线

GLM 学习曲线反映出三个核心问题：第一，训练性能虚高，多个采样比例下训练 AUC 接近 1，训练 logloss 也极低，说明模型对训练数据有过度记忆倾向；第二，验证性能偏低且波动明显，说明模型参数对训练样本扰动很敏感，泛化不稳定；第三，样本量增加后验证表现并未根本改善，到 full data 时验证 AUC 仍只有 0.5348，因此问题并非简单的数据量不够，而更可能来自模型设定与特征结构本身。

7. 模型大小分析

模型大小测试结果显示，GLM 的 object size 为 6.7177 MB，序列化后的 rds 文件大小为 1.4353 MB。这个结果说明，虽然 GLM 是传统线性模型，但在当前实现下其对象中保留了较多拟合中间信息，例如 model frame、residuals、fitted values、terms 和 weights，因此实际内存占用并不小。就部署与存储效率而言，GLM 在这方面并不占优。

8. 推理速度分析

推理速度方面，GLM 的单样本平均推理时间为 0.023 s，批量（1024 条样本）平均推理时间为 0.0737 s，batch p50 为 0.05 s。说明该模型在单样本和批量预测场景下都能较快完成推理，具备基本的落地可行性。不过从批量推理表现来看，其效率仍有进一步优化空间。

9. 结论与改进建议

9.1 当前 GLM 的定位

这是一个可用的 baseline（基线）模型：AUC ~ 0.66-0.67，泛化稳定（TEST 略好于 VAL）。但在“可落地分类”层面：Precision 很低（约 4%），F1 约 0.08，LogLoss 偏大（校准差）。所以更适合作为对比基线、流程验证、特征有效性初筛；不建议作为最终最优模型。

9.2 优先级最高的两项改进（强烈建议）

1. 把 GLM 换成 glmnet（L1/L2 正则逻辑回归）

现在的特征明显共线性很重，glm 会出现系数爆炸；glmnet 能显著稳定系数、改善校准、自动做特征收缩。

2. 主模型升级为 LightGBM（或 XGBoost）

特征（窗口计数、比率、recency）天然有非线性阈值效应，树模型通常显著提升 AUC/PR-AUC。

9.3 阈值策略建议

当前阈值 0.05 是“偏召回”的方案。后续可按目标改阈值选择方式：

- 想多捞潜在购买 → 最大化 Recall 或 Fβ（β>1）
- 想更准 → 在 scan 表里选择 Precision≥某阈值（例如 10%）时 Recall 最大
- 用 PR 曲线挑 operating point（更贴合不平衡）