1. 项目与任务定义

• 任务目标：基于用户行为统计特征（user / item / user-item 多层特征），预测该 (user_id, item_id) 是否会产生购买行为（label_buy）。
• 任务类型：二分类（购买=1 / 不购买=0）。
• 模型：加权 Logistic Regression（GLM, binomial）：使用样本权重处理类别不平衡（正类权重提升）。

2. 模型训练与评估策略

2.1 阈值与两类指标体系

包含两类指标：

(1) 阈值无关（排序能力）指标

• AUC-ROC：衡量模型对"正样本排在负样本前"的能力（越大越好）。
• PR-AUC：在正类稀少时更敏感的排序指标（越大越好）。

注意：AUC/PR-AUC 是基于概率排序的，不依赖分类阈值，所以在阈值扫描表里它们通常不变或变化很小，这是正常的。

(2) 阈值相关（落地分类）指标

• Precision / Recall / F1 / Accuracy：依赖你选定的阈值（threshold）。
• LogLoss：概率校准误差（越小越好），反映"预测概率是否可信"。

2.2 阈值选择策略

• 验证集阈值扫描，并选择 F1 最大的阈值作为最终阈值。
• 最终选择阈值为：0.05

3. 评估结果（真实输出）

3.1 验证集最优结果（VAL，threshold=0.05）

• Threshold：0.05
• AUC-ROC：0.6629
• PR-AUC：0.0378
• Accuracy：0.7243
• Precision：0.0425
• Recall：0.5217
• F1：0.0787
• LogLoss：7.3895

解读：

1. 排序能力：AUC≈0.663：明显优于随机（0.5），但强度一般（通常 0.75+ 才算明显强模型）。
2. PR-AUC≈0.03：在购买为少数类场景下，PR-AUC 常较低；该值说明模型对正类的排序提升有限。
3. 分类层面：Recall≈0.52、Precision≈0.043 → F1≈0.079：模型在这个阈值下属于"偏召回"的策略：能找回约一半正类，但误报多（预测为买的样本里只有约 4.25% 真的买）。
4. LogLoss 很高（7.39）：概率校准较差/输出概率分布异常/共线性导致系数不稳定，需要后续修正。

3.2 测试集结果（TEST，仍用 threshold=0.05）

• Threshold：0.05

- AUC-ROC：0.6700
- PR-AUC：0.0405
- Accuracy：0.7387
- Precision：0.0444
- Recall：0.5226
- F1：0.0818
- LogLoss：6.7939

解读：泛化稳定且略好

TEST 的 AUC/PR-AUC/F1 都略高于 VAL（AUC 0.670 > 0.663，F1 0.0818 > 0.0787），说明：

1. 没出现"验证集好、测试集崩"的过拟合现象；
2. 切分策略与训练流程整体稳定；
3. 但整体仍属于 baseline 水平（可用来对比更强模型）。

3.3 阈值扫描结果的结论

1. 最优阈值非常低（0.05）
   - 典型不平衡分类：如果用默认 0.5，模型会预测为"买"的太少，Recall 会更差。
   - 0.05 说明：模型输出的购买概率整体偏低或正类确实稀少，需要阈值调节才能落地。
2. Precision/Recall/F1 随阈值变化不大
   - 预测概率的分布"挤在某个区间"，调阈值不会产生很大结构性变化。
   - 很难通过阈值显著提升 Precision（精确率）；
   - 更需要通过 更强模型/更好特征/更合理标签来提升区分度。

4. 特征重要性分析

4.1 强特征（显著且影响大）

按|z|值排序，你最强的一批特征集中在 user-item 交互强度 与 商品整体转化特征：

- ui_act_total（z=9.44，p≈3.86e-21）
  user-item 总交互次数越多，购买概率越高（强正相关）
- ui_cart_rate（z=7.58，p≈3.46e-14）
  user-item 加购/浏览比越高，购买概率越高（强正相关）
- i_buy_share（z=7.25，p≈4.12e-13）
  商品购买占比越高，越可能买（商品"更容易转化"）
- i_buy（z=5.93，p≈3.08e-09）
  商品历史购买越多（热度/受欢迎），更可能买
- i_user_nunique（z=4.54，p≈5.61e-06）
  互动过该商品的用户越多，商品越热门，购买概率更高

模型主要依赖 "用户-商品交互强度/转化倾向（ui）" + "商品热度/转化（i）" 来区分是否购买。

4.2 弱特征（不显著或贡献很小，可作为删减候选）

共有 20 个特征 p>0.05，说明在 GLM 线性框架下它们对结果的贡献不稳定或被共线性稀释。

最弱的几个（p 接近 1）：

- ui_user_item_buy_rate_mix（p≈0.995，几乎没用）
- i_view_6d（p≈0.969）
- u_buy（p≈0.934）
- u_fav（p≈0.872）

• u_fav_rate（p≈0.426）

注意：GLM 的“不显著”不等于“完全没用”，因为你的计数/窗口特征很容易高度相关（共线性），会造成“贡献被分摊”。

更稳的删特征依据应该综合：单变量 AUC/IV + 多变量置换重要性 + 共线性过滤。

4.3 异常信号：系数极端大（±100 级别）

出现了非常极端的系数（例如 u_cart ≈ -143、i_act_total ≈ -105、ui_user_item_pop ≈ +119）。

通常意味着至少存在一种问题：

1. 严重共线性：大量计数/窗口特征重复表达同一信息
2. 尺度/分布问题：部分特征量级很大或分布极端，导致 GLM 系数不稳定
3. 近似分离：某些特征在某些范围几乎决定标签，使得系数飙升

也能解释为什么 LogLoss 非常高：概率输出校准不可靠。

5. 结论与改进建议

5.1 当前 GLM 的定位

这是一个可用的 baseline（基线）模型：AUC ~ 0.66-0.67，泛化稳定（TEST 略好于 VAL）。但在“可落地分类”层面：Precision 很低（约 4%），F1 约 0.08，LogLoss 偏大（校准差）。所以更适合作为对比基线、流程验证、特征有效性初筛；不建议作为最终最优模型。

5.2 优先级最高的两项改进（强烈建议）

1. 把 GLM 换成 glmnet（L1/L2 正则逻辑回归）

现在的特征明显共线性很重，glm 会出现系数爆炸；glmnet 能显著稳定系数、改善校准、自动做特征收缩。

2. 主模型升级为 LightGBM（或 XGBoost）

特征（窗口计数、比率、recency）天然有非线性阈值效应，树模型通常显著提升 AUC/PR-AUC。

5.3 阈值策略建议

当前阈值 0.05 是“偏召回”的方案。后续可按目标改阈值选择方式：

• 想多捞潜在购买 → 最大化 Recall 或 Fβ（β>1）

• 想更准 → 在 scan 表里选择 Precision≥某阈值（例如 10%）时 Recall 最大

• 用 PR 曲线挑 operating point（更贴合不平衡）