特征设计

1. 数据与时间窗设计

1.1 原始数据字段

- user_id：用户 ID
- item_id：商品 ID
- item_category：商品类目
- behavior_type：行为类型（view / fav / cart / buy）
- time：行为发生时间

1.2 统计窗口与口径

为避免数据泄漏，所有特征仅使用“特征窗口”内的数据构建，标签使用“标签窗口”内的数据构建。

- 全窗口累计特征：在特征窗口内累计行为次数、去重数、占比等。
- 近 1/3/7 天特征：以样本的“窗口截止时间 T”为基准，统计最近 1/3/7 天内的行为次数。
- 时序位置特征：first_time / last_time / recency（距离 T 的时间差）等。
- split 字段（train/val/test）按用户分层切分生成，防止同一用户未来行为泄漏到训练集。

2. 特征总体结构与命名

2.1 角色与层级

- meta / id：user_id, item_id
- Label：label_buy
- feature：可用于建模输入的特征

2.2 命名规则

- 商品侧：i_ 前缀（item）
- 用户侧：u_ 前缀（user）
- 交互侧：ui_ 前缀（user_item）
- 时间窗口：_1d/_3d/_7d 表示近 1/3/7 天统计
- 比例特征：*_rate、*_share（比值/占比）
- 时间特征：*_first_time, *_last_time, *_recency_hours

3. 特征定义与构建逻辑

3.1 商品侧特征（item level）

A. 计数类

- i_act_total：商品总行为数（view+fav+cart+buy）
- i_view / i_fav / i_cart / i_buy：商品各行为次数
- i_user_nunique：与该商品交互过的去重用户数
- i_cat：商品类目 ID（取众数/唯一值）

构建逻辑：

对特征窗口内日志按 item_id 聚合：

```
i_view = count(behavior_type == "view")
i_act_total = count(*)
i_user_nunique = nunique(user_id)
```

B. 时间类

• i_first_time：该商品首次被交互时间（min(time)）
• i_last_time：该商品最近被交互时间（max(time)）
C. 比例/占比类
• i_buy_rate = i_buy / max(i_view, 1)（购买转化/曝光比，防止除 0）
• i_cart_rate = i_cart / max(i_view, 1)
• i_buy_share = i_buy / max(i_act_total, 1)（购买占所有行为比例）
D. 近 1/3/7 天趋势类
• i_act_1d / i_act_3d / i_act_7d：近 1/3/7 天商品总行为数
• i_buy_1d / i_buy_3d / i_buy_7d：近 1/3/7 天商品购买次数
构建逻辑：以窗口截止时间 T 为基准

```
i_act_7d = count(item_id==i AND time in (T-7d, T])
i_buy_7d = count(item_id==i AND behavior=="buy" AND time in (T-7d, T])
```

3.2 用户侧特征（user level）

A. 计数类
• u_act_total：用户总行为数
• u_view / u_fav / u_cart / u_buy：用户各行为次数
• u_item_nunique：用户交互过的去重商品数
• u_cat_nunique：用户交互过的去重类目数
• u_day_nunique：活跃天数
• u_hour_nunique：活跃小时数
• u_label_buy：用户购买次数
B. 时间类
• u_first_time：用户首次交互时间
• u_last_time：用户最近交互时间
C. 偏好类
• u_pref_hour：用户最活跃小时（统计各小时行为次数，取 argmax）
• u_pref_dow：用户最活跃星期（1=Mon..7=Sun，取 argmax）
D. 比例/占比类
• u_buy_rate = u_buy / max(u_view, 1)
• u_cart_rate = u_cart / max(u_view, 1)
• u_fav_rate = u_fav / max(u_view, 1)
• u_buy_share = u_buy / max(u_act_total, 1)
E. 近 1/3/7 天趋势类
• u_act_1d/_3d/_7d：近 1/3/7 天用户总行为数
• u_buy_1d/_3d/_7d：近 1/3/7 天用户购买次数

3.3 用户-商品交互特征（user_item level）

最核心的“个体意图”特征，直接刻画用户对该商品的互动强弱、转化倾向和近期热度。

A. 计数类（全窗口累计）
• ui_act_total：该用户对该商品总行为数
• ui_view / ui_fav / ui_cart / ui_buy：交互行为次数
B. 去重活跃度
• ui_day_nunique：该 user-item 的活跃天数
• ui_hour_nunique：该 user-item 的活跃小时数
C. 时间与新鲜度

• ui_first_time：首次交互时间
• ui_last_time：最近交互时间
• ui_recency_hours：距离窗口截止时间的小时数
• ui_recency_hours = (T - ui_last_time) / 3600

D. 转化倾向（比率）

• ui_buy_rate = ui_buy / max(ui_view, 1)
• ui_cart_rate = ui_cart / max(ui_view, 1)
• ui_fav_rate = ui_fav / max(ui_view, 1)

E. 近 1/3/7 天趋势（强烈建议保留）

• ui_act_1d/_3d/_7d：近 1/3/7 天交互总行为数
• ui_buy_1d/_3d/_7d：近 1/3/7 天购买次数

F. 交叉组合（cross features）

• ui_user_item_pop = u_act_total * i_act_total（或标准化后相乘更稳健）

表示：高活跃用户 × 高热商品 的“相遇”强度。

• ui_user_item_buy_rate_mix = mean(u_buy_rate, i_buy_rate)

表示：用户整体购买倾向 与 商品整体可购买性 的折中先验。

4. 预处理方法（Preprocessing）

4.1 排除列（不参与数值预处理的列）

"user_id","item_id","label_buy","split","u_pref_hour","u_pref_dow","i_cat","u_first_time","u_last_time","i_first_time","i_last_time","ui_first_time","ui_last_time"

4.2 数值列集合 num_cols

• 取 train_dt 中所有 numeric 列，再剔除 exclude_cols

4.3 log1p 变换（仅对 count-like 特征）

使用正则筛选 count-like 字段名：

```
count_like <- grep("(_act_|_view|_fav|_cart|_buy(?!_rate)|_nunique|_pop|_1d|_3d|_7d)",
                   num_cols, value=TRUE, perl=TRUE)
```

对 train_dt/val_dt/test_dt 的这些列执行 x := log1p(x)

4.4 z-score 标准化

对 numeric columns（包含 count-like 与非 count-like 的数值列）：

• mu[cn] = mean(train_dt[[cn]])
• sdv[cn] = sd(train_dt[[cn]])
• 若 sdv 为 0 或 NA，则置为 1
• 转换：x := (x - mu[cn]) / sdv[cn]，对 train/val/test 都用同一组 mu/sdv 变换。

5. 特征清单（按层级汇总）

当前字典包含以下层级特征：

- Item（14）：i_act_total, i_fav, i_cart, i_buy, i_user_nunique, i_cart_rate, i_buy_share, i_act_1d, i_act_3d, i_act_7d, i_buy_1d, i_buy_3d, i_buy_7d
- User（16）：u_fav, u_cart, u_buy, u_item_nunique, u_cat_nunique, u_day_nunique, u_hour_nunique, u_cart_rate, u_fav_rate, u_buy_share, u_act_1d, u_act_3d, u_act_7d, u_buy_1d, u_buy_3d, u_buy_7d
- User-Item（13）：ui_act_total, ui_fav, ui_cart, ui_day_nunique, ui_hour_nunique, ui_cart_rate, ui_fav_rate, ui_recency_hours, ui_act_1d, ui_act_3d, ui_act_7d, ui_user_item_pop,

ui_user_item_buy_rate_mix

- Meta/ID/Label（4）：user_id, item_id, split, label_buy